

Deep Hunter Exoplanet

Clasificación visual de tránsitos planetarios mediante Deep Learning

1. Motivación e hipótesis

Deep Hunter Exoplanet es un proyecto de Computer Vision orientado a estudiar si una red neuronal convolucional puede detectar patrones compatibles con tránsitos de exoplanetas transformando curvas de luz astronómicas en imágenes.

Hipótesis: ¿Puede una CNN identificar patrones de tránsito planetario si una serie temporal astronómica se representa como imagen?

El objetivo no es confirmar científicamente exoplanetas, sino crear un sistema preliminar de filtrado de candidatos.

Pipeline


Curva de luz → Generación de imagen → ResNet18 Transfer Learning → Planet / False Positive

2. Dataset y preprocesado

Se generó un dataset sintético inspirado en observaciones astronómicas reales.

Clase Planet:


- Caída única de luminosidad.
- Profundidad y duración variables.
- Ruido instrumental simulado.



Ejemplo de candidato Planet

Clase False Positive:

- Ruido aleatorio.
- Variabilidad estelar.
- Patrones similares a binarias eclipsantes.



Ejemplo de False Positive

3. Modelo y entrenamiento


Se utilizó ResNet18 preentrenada en ImageNet mediante Transfer Learning. La última capa fue sustituida para realizar clasificación binaria.

Parámetro	Valor
Imagen	224x224
Batch size	32
Epochs	5
Optimizer	Adam
Learning rate	1e-4

4. Resultados experimentales

Experimento	Accuracy	Precision	Recall	F1
Baseline	1.000	1.000	1.000	1.000
Hard Dataset	0.975	0.961	0.990	0.975
Kepler Style	0.980	0.956	1.000	0.978

El primer experimento mostró que el problema era demasiado sencillo. Posteriormente se aumentó la dificultad añadiendo ruido, falsos positivos más realistas y una adaptación visual estilo Kepler.



Matriz de confusión del modelo Kepler Style

5. Domain Shift y prueba real Kepler-8b

El modelo Hard Dataset obtuvo inicialmente:

Planet: 57%


False Positive: 43%

Tras crear un dataset Kepler Style más próximo al dominio real:

Planet: 100%

False Positive: 0%


Esto muestra la importancia de adaptar la distribución de entrenamiento.



6. Despliegue y conclusiones

Aplicación desplegada con Gradio en HuggingFace Spaces:

<https://huggingface.co/spaces/Giotto/deep-hunter-exoplanet>



Conclusiones:

- Una CNN puede aprender patrones visuales asociados a tránsitos.
- Métricas perfectas no garantizan generalización.
- El diseño del dataset es crítico.
- Reducir el domain shift mejora la robustez.

Trabajo futuro:

Kepler/TESS reales, CNN 1D, Fourier, Wavelets y arquitectura inspirada en VARnet.